



# 期望和方差

主讲人：刘宏志

[liuhz@ss.pku.edu.cn](mailto:liuhz@ss.pku.edu.cn)



北京大学



## 期望的起源

- 1654年，一赌徒向法国大数学家帕斯卡提出了如下问题：
  - 甲乙两人赌技相当，各自赌金100法郎，并约定先胜3局者为胜，取得全部200法郎。
  - 由于出现意外情况，在甲胜2局乙胜1局时，不得不终止赌博，如果要分赌金，该如何分配才算公平？

**分法1：**把钱分为3份，胜了2局的拿2份，胜了1局的拿1份

**分法2：**约定是胜3局者为胜，而谁都没达到，所以应一人一半



北京大学



## 期望的起源

- 1654年，一赌徒向法国大数学家帕斯卡提出了如下问题：
  - 甲乙两人赌技相当，各自赌金100法郎，并约定先胜3局者为胜，取得全部200法郎。
  - 由于出现意外情况，在甲胜2局乙胜1局时，不得不终止赌博，如果要分赌金，该如何分配才算公平？
- 帕斯卡和费马通信讨论了此问题，并于1654年共同建立了概率论的第一个基本概念：数学期望
  - 不考虑平局，最多5局就能分出胜负（一方胜3局，另一方胜2局）
  - 已经进行了3局，最多还需进行2局
  - 甲胜的概率： $1/2 + 1/2 * 1/2 = 3/4$ ，乙胜的概率： $1/2 * 1/2 = 1/4$



北京大学



## 期望的起源

- 甲胜的概率为 $3/4$ ，乙胜的概率为 $1/4$
- 甲乙获胜的可能性大小比值为 $3:1$
- 甲应获得赌金的 $3/4$ ，而乙只能获得赌金的 $1/4$
- 甲能“期望”获得数目为：
  - $200 * 3/4 + 0 * 1/4 = 150$  (法郎)
- 乙能“期望”获得数目为：
  - $200 * 1/4 + 0 * 3/4 = 50$  (法郎)



北京大学



# 期望的定义

- 离散型随机变量

- 如果X是频率函数为 $p(x)$ 的离散型随机变量，且满足  $\sum_i |x_i|p(x_i) < \infty$ ，则X的期望为：

$$E(X) = \sum_i x_i p(x_i)$$

- 如果和式发散，则期望无定义

- 连续型随机变量

- 如果X是密度函数为 $f(x)$ 的连续型随机变量，且满足  $\int_{-\infty}^{\infty} |x|f(x) dx < \infty$ ，则X的期望为：

$$E(X) = \int_{-\infty}^{\infty} xf(x) dx$$

- 如果积分发散，则期望无定义



北京大学



## 案例：圣彼得堡悖论

- 一个赌徒按照如下策略赌博：
  - 开始下注1美元，如果输了，就接着双倍下注
  - 连续双倍下注，直到最终获胜
  - 当他最终获胜时，他稳赢1美元
- 此策略是否合理？
- 令X表示最后一局（获胜的一局）的赌注
  - $P(X=2^k)=1/2^{k+1}$
  - $E(X) = \sum_{n=0}^{\infty} nP(X = n) = \sum_{k=0}^{\infty} 2^k \frac{1}{2^{k+1}} = \infty$







# 马尔可夫不等式

- 定理：如果随机变量 $X$ 满足 $P(X \geq 0) = 1$ ，且 $E(X)$ 存在，则对任意 $t > 0$ ,

$$P(X \geq t) \leq E(X)/t。$$

- 证明：
$$E(X) = \sum_x xp(x) = \sum_{x < t} xp(x) + \sum_{x \geq t} xp(x)$$

$$E(X) \geq \sum_{x \geq t} xp(x) \geq \sum_{x \geq t} tp(x) = tP(X \geq t)$$

- 变形：令 $t = kE(X)$ ，则 $P(X \geq kE(X)) \leq 1/k$
- 应用：

➤ 不超过1/5的人口会有超过5倍于人均收入的收入



北京大学



# 随机变量函数的期望

- 假设  $Y=g(X)$ .
  - 如果  $X$  是频率函数为  $p(x)$  的离散型随机变量，且满足  $\sum |g(x)|p(x) < \infty$ ，则：

$$E(Y) = \sum_x g(x)p(x)$$

- 如果  $X$  是密度函数为  $f(x)$  的连续型随机变量，且满足  $\int_{-\infty}^{\infty} |g(x)|f(x) dx < \infty$ ，则：

$$E(Y) = \int_{-\infty}^{\infty} g(x)f(x) dx$$

注意：  $E[g(X)] \neq g[E(X)]$ ，即函数的期望不等于期望的函数



北京大学





## 联合分布函数的期望

- 设 $X_1, \dots, X_n$ 是具有联合分布的随机变量,  $Y=g(X_1, \dots, X_n)$ .
  - 如果 $X$ 是频率函数为 $p(x_1, \dots, x_n)$ 的离散型随机变量, 且满足 $\sum |g(x_1, \dots, x_n)|p(x_1, \dots, x_n) < \infty$ , 则:

$$E(Y) = \sum g(x_1, \dots, x_n)p(x_1, \dots, x_n)$$

- 如果 $X$ 是密度函数为 $f(x_1, \dots, x_n)$ 的连续型随机变量, 且满足 $\int \int \cdots \int |g(x_1, \dots, x_n)|f(x_1, \dots, x_n) dx_1, \dots, dx_n < \infty$ , 则:

$$E(Y) = \int \int \cdots \int g(x_1, \dots, x_n)f(x_1, \dots, x_n)dx_1, \dots, dx_n$$





北京大学



# 联合分布

- 定义在**同一样本空间**上的**两个或两个以上**的随机变量的联合概率结构
- 两个随机变量X和Y的**联合性质**由**累积分布函数(cdf)**决定:  $F(x, y) = P(X \leq x, Y \leq y)$ 
  - 累积分布函数给出了点(X, Y)落入平面**半无穷矩形区域**的概率





## 联合频率函数

- 假设 $X$ 和 $Y$ 是定义在**同一样本空间**上的两个离散随机变量，分别取值 $x_1, x_2, \dots$ 和 $y_1, y_2, \dots$
- 它们的**联合频率函数**或**联合概率质量函数**为

$$p(x_i, y_j) = P(X=x_i, Y=y_j)$$

- 例：抛掷一枚均匀硬币3次，令 $X$ 表示第一次抛掷是否正面朝上， $Y$ 表示所有正面的次数
  - 样本空间为： $\Omega = \{hhh, hht, hth, htt, thh, tht, tth, ttt\}$

$x$	$y$			
	0	1	2	3
0	$\frac{1}{8}$	$\frac{2}{8}$	$\frac{1}{8}$	0
1	0	$\frac{1}{8}$	$\frac{2}{8}$	$\frac{1}{8}$





# 随机变量线性组合的期望

- 定理：如果 $X_1, \dots, X_n$ 是具有期望 $E(X_i)$ 的联合分布随机变量， $Y$ 是 $X_i$ 的的线性函数  $Y=a + \sum_{i=1}^n b_i X_i$ ，则：

$$E(Y)=a + \sum_{i=1}^n b_i E(X_i)$$

- 例：假设你收集购物券，共有 $n$ 种不同类型的购物券，且每次试验你都可以等可能地得到任一类型的购物券。你期望多少次试验才能收集到完整的券集？

➤ 令 $X_{i+1}$ 表示在收集了 $i$ 种购物券后出现第 $i+1$ 类购物券所需的次数

➤  $X_r$ 的分布为：几何分布

➤ 每次试验成功的概率为： $p=(n-r+1)/n$

➤  $E(X_r)=1/p = n/(n-r+1)$

几何分布：由无穷次伯努利试验构造而成，每次试验成功的概率为 $p$ ， $X$ 表示直到第一次成功所做的试验次数

$$E(X) = \sum_{r=1}^n E(X_r)$$

$$= \frac{n}{n} + \frac{n}{n-1} + \frac{n}{n-2} + \cdots + \frac{n}{1}$$

$$= n \sum_{r=1}^n \frac{1}{r}$$



北京大学



# 方差和标准差

- 随机变量的标准差描述分布关于中心的发散程度，度量随机变量偏离期望的平均幅度
- 定义：如果 $X$ 是具有期望 $E(X)$ 的随机变量，只要下述期望存在，则 $X$ 的方差为：

$$\text{Var}(X) = E\{[X-E(X)]^2\}$$

- $X$ 的标准差是方差的平方根
- 定理1：如果 $\text{Var}(X)$ 存在， $Y=a+bx$ ，则

$$\text{Var}(Y)=b^2\text{Var}(X)$$

- 定理2：如果 $X$ 的方差存在，也可计算如下：

$$\text{Var}(X) = E(X^2) - [E(X)]^2$$



北京大学



# 切比雪夫不等式

- 定理：令 $X$ 是均值为 $\mu$ ，方差为 $\sigma^2$ 的随机变量，则对任意 $t > 0$ ， $P(|X - \mu| \geq t) \leq \sigma^2/t^2$ .
- 设定 $t = k\sigma$ ，不等式变为

$$P(|X - \mu| \geq k\sigma) \leq 1/k^2$$

- 推论：如果 $\text{Var}(X) = 0$ ，则 $P(X = \mu) = 1$
- 应用：在所有数据中
  - 至少有3/4（或75%）的数据位于期望值2个标准差范围内
  - 至少有8/9（或88.9%）的数据位于期望值3个标准差范围内
  - 至少有24/25（或96%）的数据位于期望值5个标准差范围内



北京大学





## 案例：投资组合

- 投资者计划分投资本 $C$ 于两种资产
- 两种资产的期望收益率分别为 $\mu_1=0.1$ 和 $\mu_2=0.03$
- 设在第一种资产上的投资比率为 $\pi_1$ ，则收益为

$$R = \pi_1 R_1 + (1 - \pi_1) R_2$$

- 平均收益为： $E(R) = \pi_1 \mu_1 + (1 - \pi_1) \mu_2$
- 设第一种资产为股票（有风险），标准差为 $\sigma_1=0.075$
- 第二种资产为银行存款(无风险)，标准差为 $\sigma_2=0$
- 则投资收的标准差为： $\sigma_R = \pi_1 \sigma_1$

$\pi_1$ 越大，期望收益越大，但风险也会随之变大。



北京大学



# 协方差

- 两个随机变量的**协方差** (covariance)是它们**联合变异性的**度量，或是它们**关联性的**度量
- 定义：如果 $X$ 和 $Y$ 是分别具有期望 $\mu_X$ 和 $\mu_Y$ 的随机变量，只要下述期望存在，则 $X$ 和 $Y$ 的协方差为

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

- 性质：
  - 两个随机变量的关联是**正向**的，则协方差为正
  - 两个随机变量的关联是**反向**的，则协方差为负
  - 两个随机变量是**独立**的，则协方差为0 (**无关**的)
  - $\text{Cov}(X, X) = \text{Var}(X)$





## 协方差的双线性性质

- 定理：设  $U=a+\sum_{i=1}^n b_i X_i$  和  $V=c+\sum_{j=1}^m d_j Y_j$ ，则

$$\text{Cov}(U, V)=\sum_{i=1}^n \sum_{j=1}^m b_i d_j \text{Cov}(X_i, Y_j)$$

- 推论1：

$$\text{Var}(a + \sum_{i=1}^n b_i X_i) = \sum_{i=1}^n \sum_{j=1}^m b_i d_j \text{Cov}(X_i, X_j)$$

- 推论2：

如果  $X_i$  独立，则  $\text{Var}(\sum_{i=1}^n X_i)=\sum_{i=1}^n \text{Var}(X_i)$



北京大学



## 案例：随机游走

- 一个醉汉自实数线的点 $x_0$ 开始行走，每一步步长是期望为 $\mu$ ，方差为 $\sigma^2$ 的随机变量
- $n$ 步后的位置为： $S(n) = x_0 + \sum_{i=1}^n X_i$


$$E(S(n)) = x_0 + E(\sum_{i=1}^n X_i) = x_0 + n\mu$$

$$\text{Var}(S(n)) = \text{Var}(\sum_{i=1}^n X_i) = n\sigma^2$$

- 若 $\mu > 0$ ，对于较大的 $n$ ，他将以较高的概率处于 $x_0$ 的右侧



北京大学





## 相关系数

- 定义：如果 $X$ 和 $Y$ 的方差和协方差都存在，且方差非零，则 $X$ 和 $Y$ 的相关系数为：

$$\rho = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$

- 性质：

- $-1 \leq \rho \leq 1$ .  $\rho = \pm 1$  当且仅当  $P(Y = a + bX) = 1$ , 其中  $a$  和  $b$  为常数
- 相关系数无量纲
- 如果 $X$ 和 $Y$ 进行线性变换，相关系数保持不变



北京大学





# 总结

- 期望：
  - 随机变量的**平均值**，可视为密度或频率函数的**中心**
  - 也称为随机变量的**位置参数**
- 标准差：
  - 描述概率分布关于中心的**发散程度**
  - 随机变量**偏离**期望的平均**幅度**
- 协方差：
  - 两个随机变量之间**关联度**的度量



北京大学